# A4实战全流程

## 一、实战前准备

**确认完成A4实战作业指导课的学习，熟悉了完整微调流程，定义好微调任务，准备好相对应的数据集做好清洗**

**需注意：**

准备好linux服务器版本的Miniforge安装包用于管理环境，下载网址：

Releases · conda-forge/miniforge · GitHub

- 推荐版本 Miniforge3-26.3.2-3-Linux-x86_64.sh
- 微调任务场景需清晰明确，寻找的数据集内容要相符合，最终才能形成良好的从任务定义→微调执行→效果评估的完整项目链路
- 模型选择，明确只做文生文的语言模型的微调，如qwen2.5-7b、llama3-8b
- 数据集需要进行清洗
    a. **规模7000-8000条左右训练集, 请另备1000条的验证集和1000条的测试集**
    b. **要适应llamafactory支持处理的数据格式，如SFT**

```
{
  "instruction": "用户提问内容",
  "input": "", // 可选补充信息
  "output": "标准回答文本"
},
```

```

```

- 明确微调框架使用llamafactory，需提前下载到本地进行解压，详细见第五点
- 微调效果的评估使用人工评估的方法，比如可根据微调任务提前建立一套评分标准，评估时拿数据集里的问题提问，去看它的生成回复是否达到要求，如90%的回复可达到85分就可以视作微调效果ok.
- 整理所有准备工作，完成申请文档

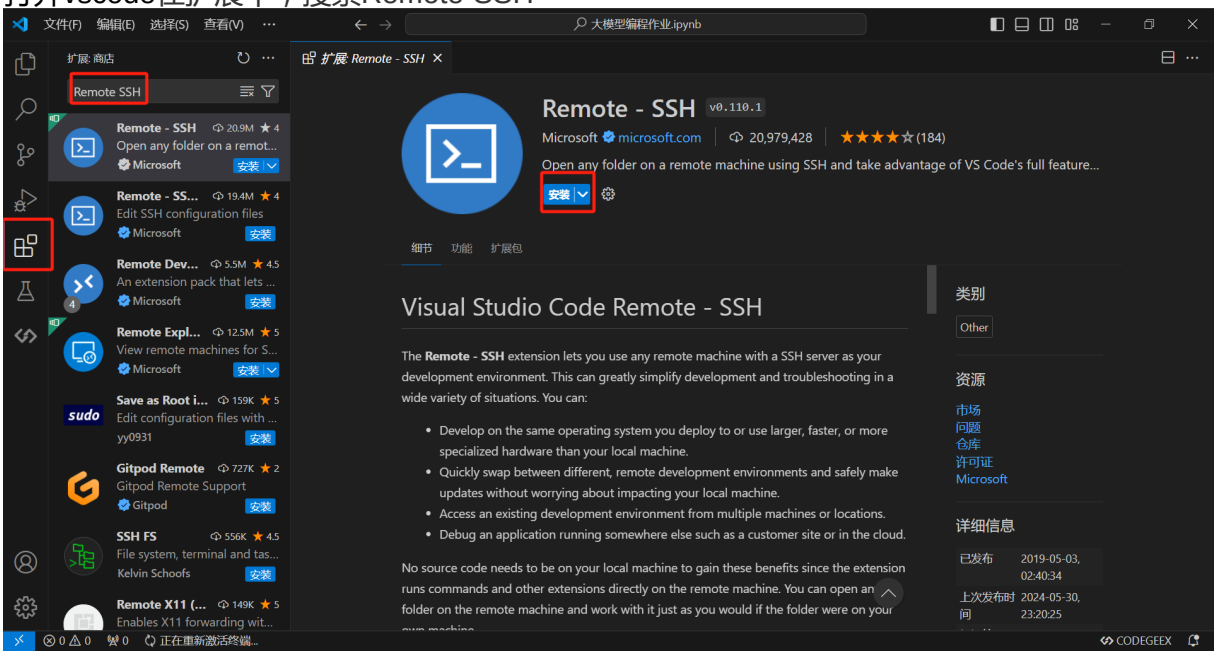
1. 微调模型选择(只能选语言模型)
2. 数据集准备(数据规模有多少条、清洗后的数据示例)
3. Anaconda安装包准备(linux版本)
4. linux服务器的登录指令（由助教老师提供，同学需要了解如何通过ssh登录服务器）
5. 微调指令准备

## 二、登录服务器

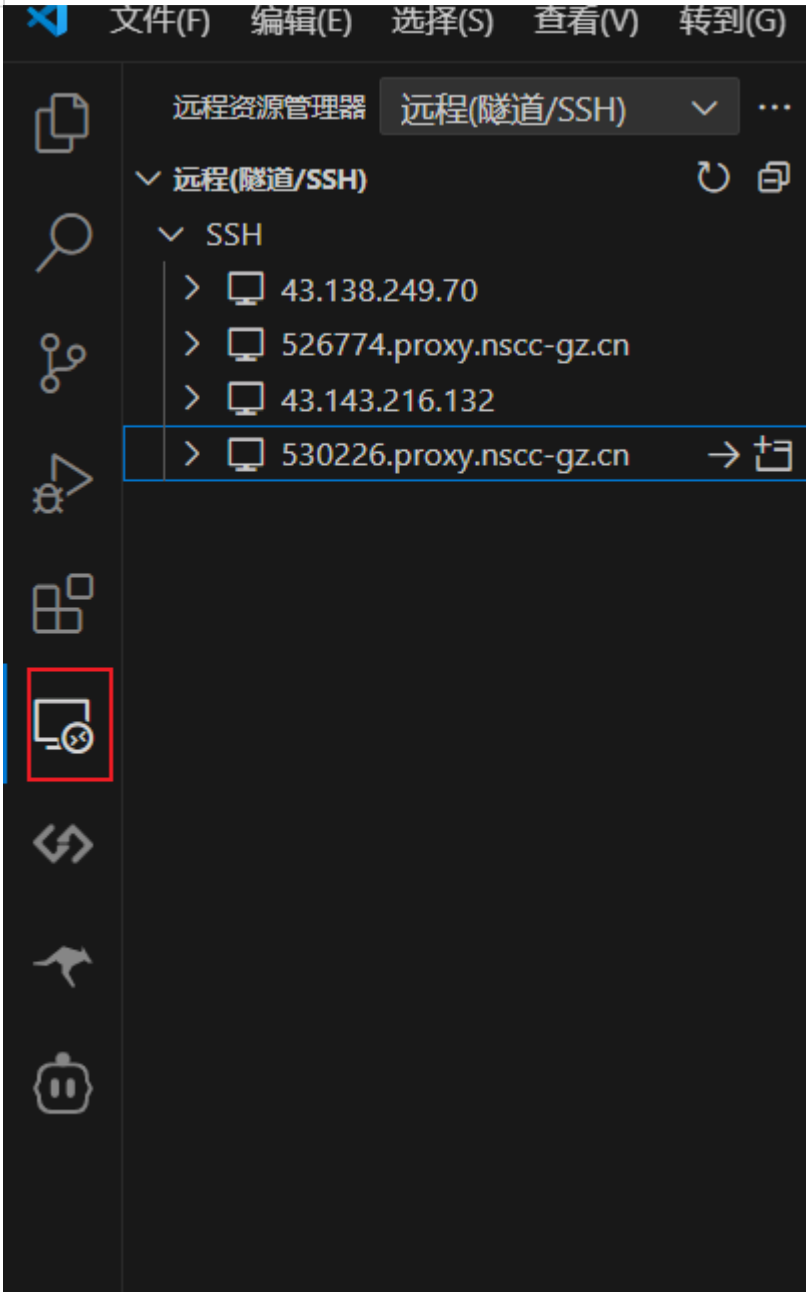
同学实战开始之前会收到登录账号，格式如下

账号：ssh xxx@xxx.xxx.xxx.xxx -p xxxxx
密码：xxxxxxxxx

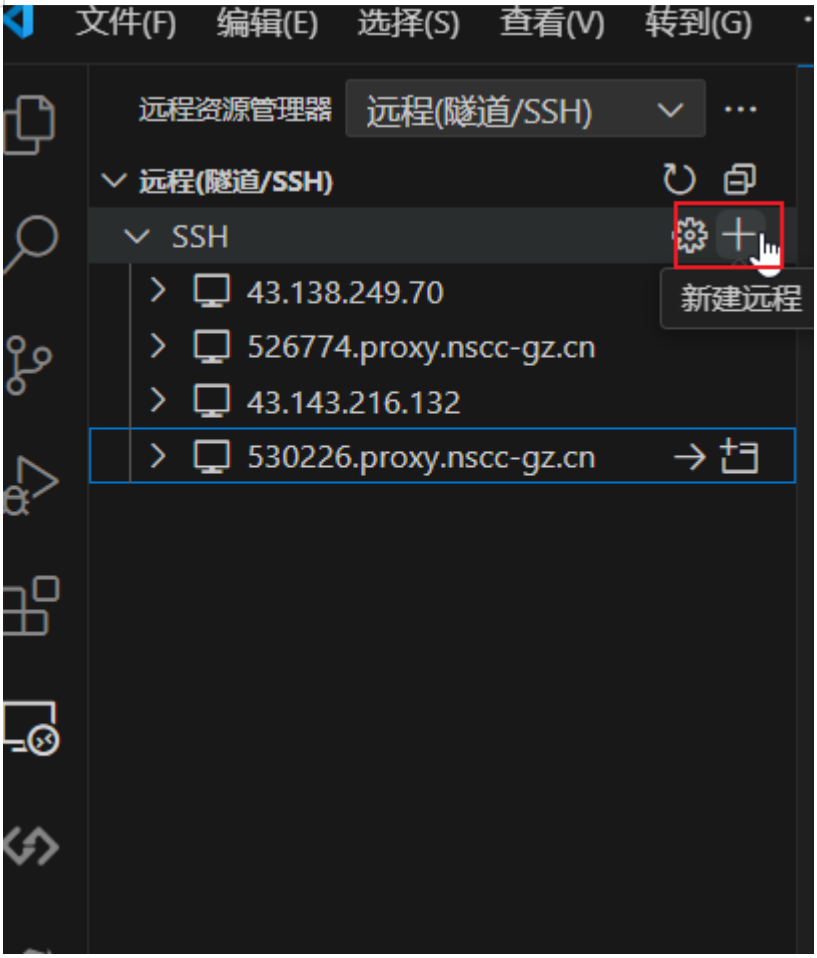
打开vscode在扩展中，搜索Remote-SSH



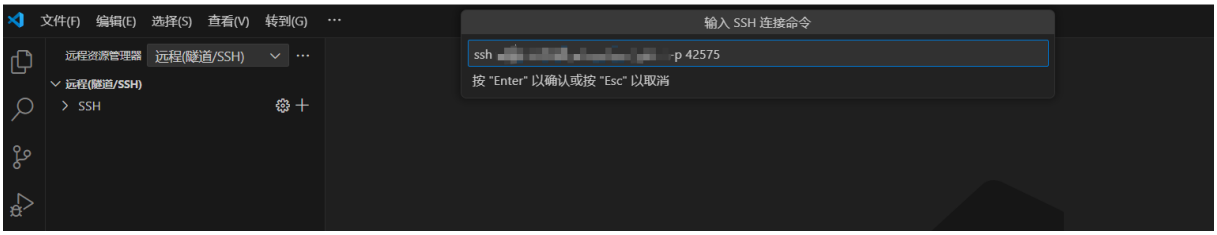

安装完成后点击左侧工具栏的远程SSH按钮


文件(F)
编辑(E)
选择(S)
查看(V)
转到(G)
远程资源管理器
远程(隧道/SSH)
远程(隧道/SSH)
SSH
43.138.249.70
526774.proxy.nscc-gz.cn
43.143.216.132
530226.proxy.nscc-gz.cn

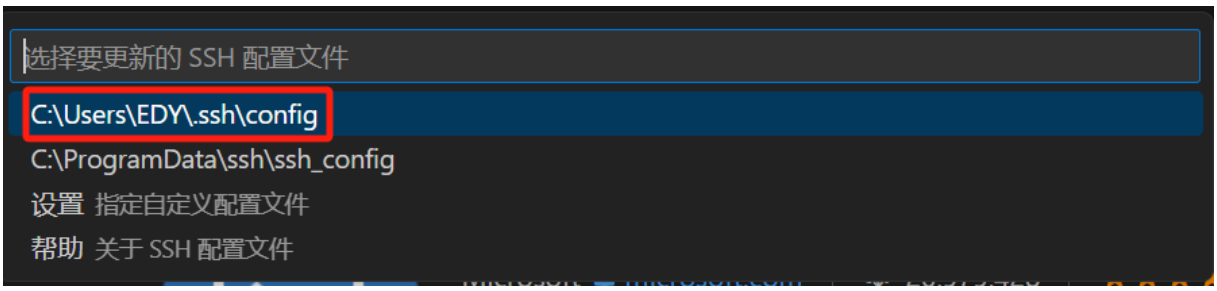
点击+号



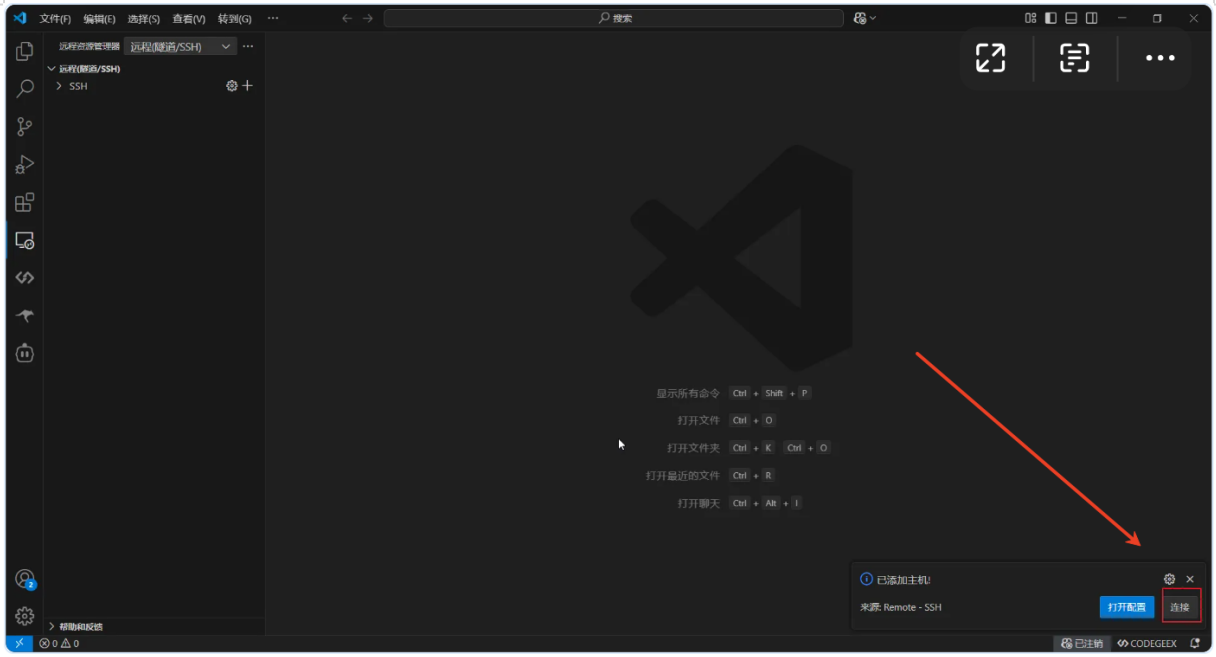

输入账号，回车



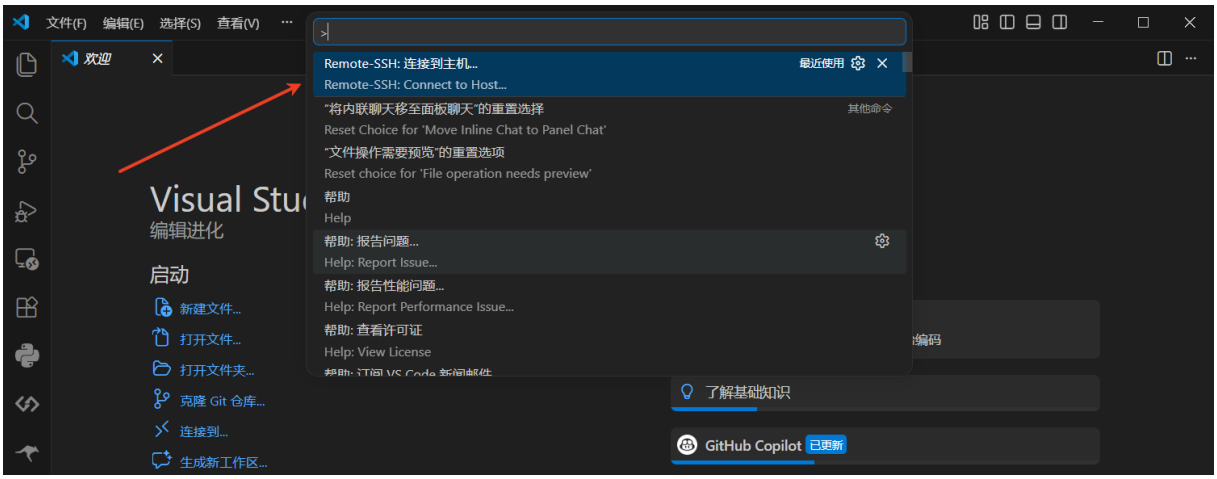

弹出config配置文件需要选择，默认选择第一个



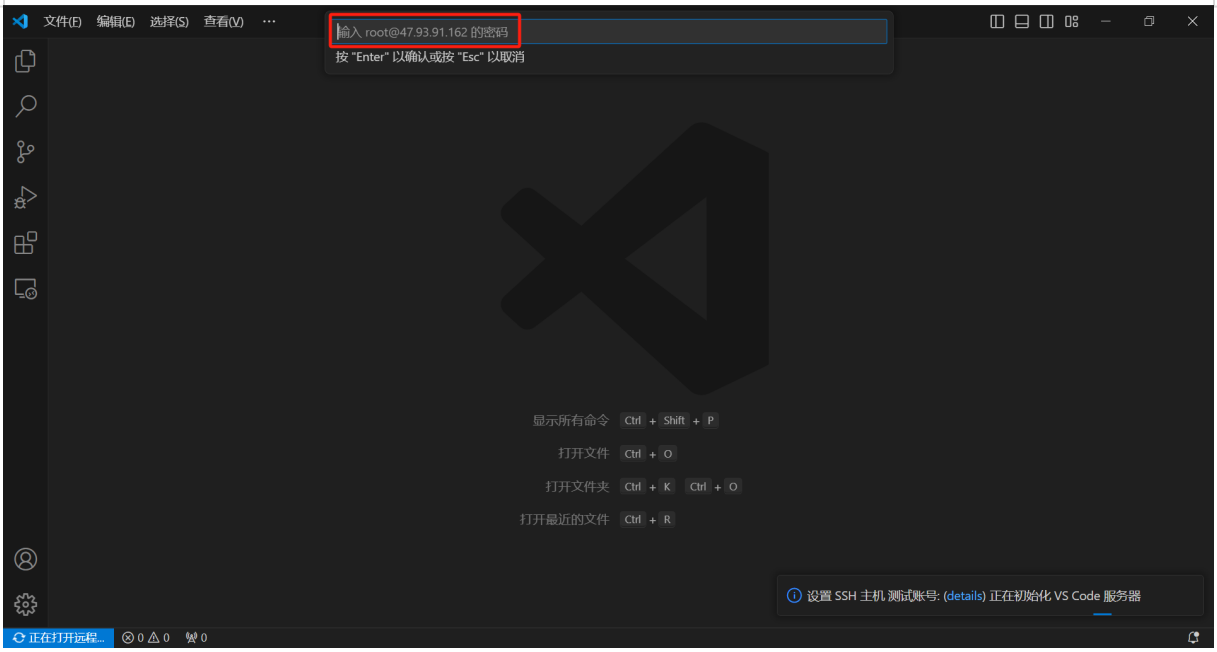

点击连接



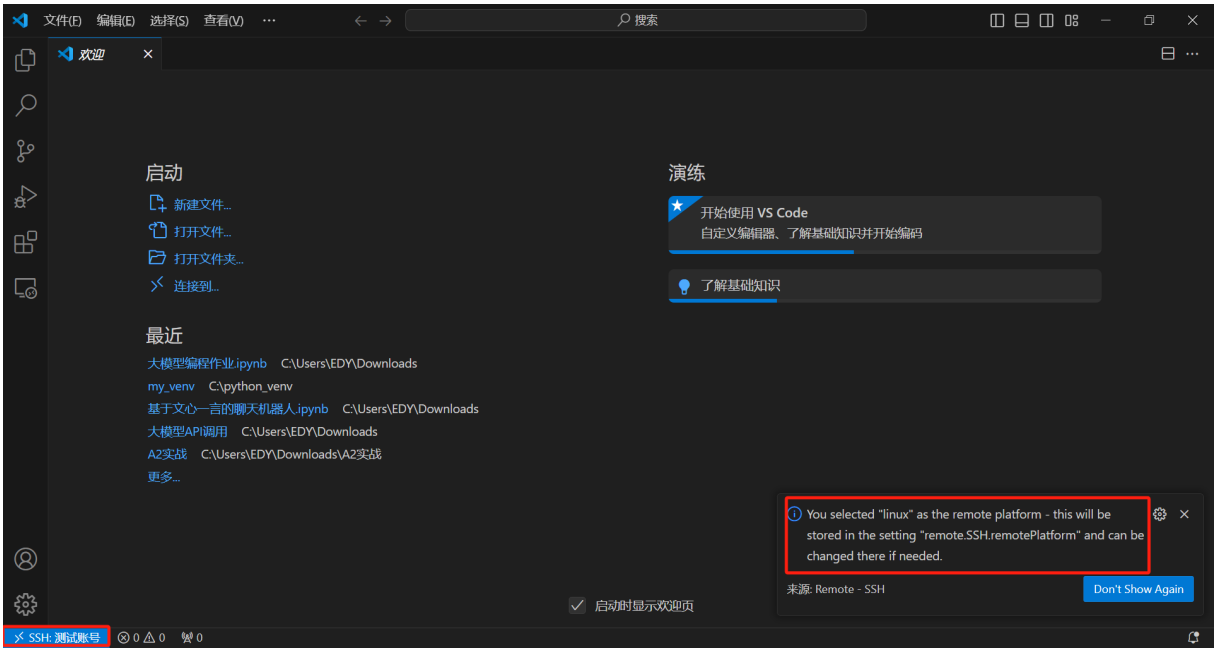

如果没有出现连接按钮，可以按下 ctrl shift p，在弹出的窗口点击远程连接到主机，选择刚刚配置好的主机



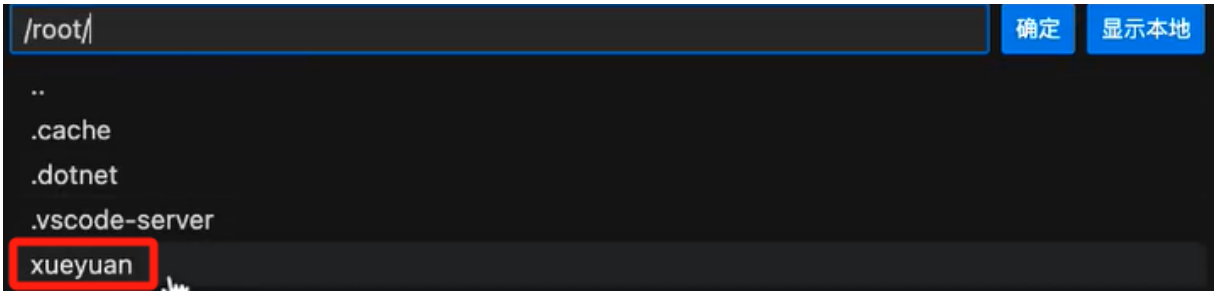

等待连接到服务器，中间可能会需要选择系统linux，并输入密码



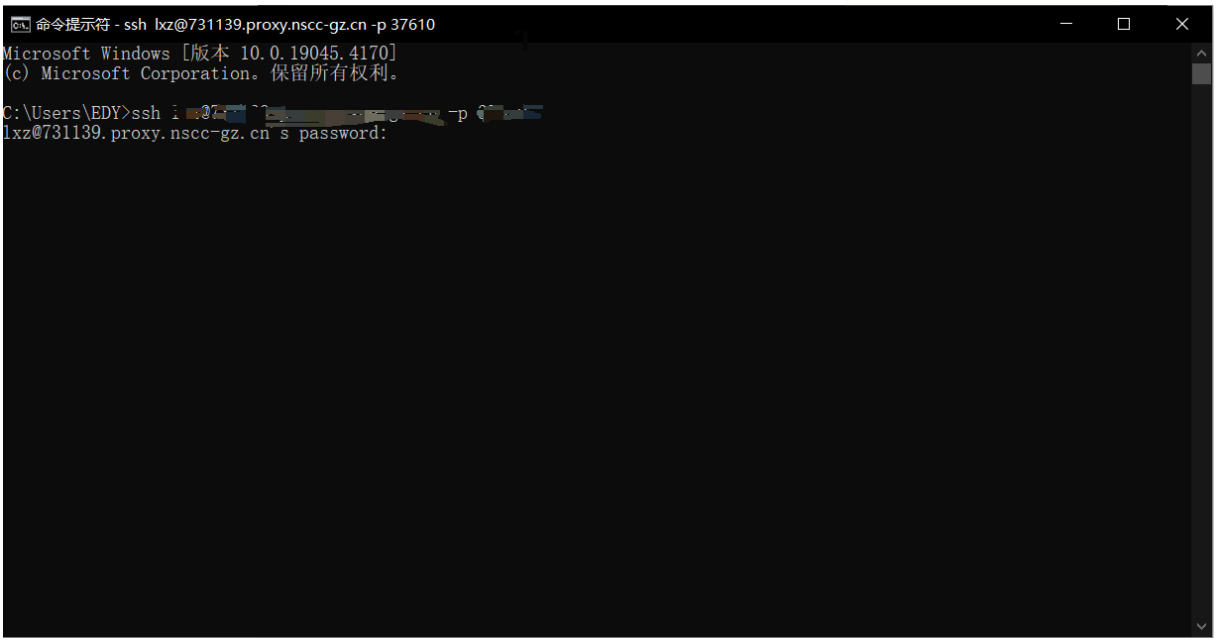

登录完成会在左下角蓝色框中出现"显卡账号"，现在vscode就连接上了linux系统服务器




选择"打开文件夹"，服务器已经有同学对应命名的文件夹供账户访问，以建好的文件夹"xueyuan"为例，进入文件后，就可以进行下载数据、模型等任务



如果因网络问题登录长时间停留在“vscode server配置”导致无法连接，可以先通过本地cmd终端进行ssh登录，直接输入完整的ssh登录命令，密码需手动输入，且linux系统登录密码不会明文显示，正常输入即可




登录成功后执行

```
source /app/bin/proxy.sh
```

之后即可正常通过vscode登录，重复vscode登录步骤即可

# 三、上传需要使用的文件

本地准备好的Anaconda安装包、解压好的llamafactory文件夹等均可以通过scp指令上传服务器

在本地终端（注意不是vscode的linux终端）运行scp指令进行服务器文件上传

```
scp -r -P 端口号 /path/to/local/directory username@remotehost:/path/to/remote/d
```

- scp：这是scp命令名称
- -r：告诉scp递归地复制整个目录及其内容
- -P 端口号：登录远程服务器的账号中的端口号
- /path/to/local/directory：想要上传的本地文件夹路径
- username@remotehost：登录远程服务器的账号
- /path/to/remote/directory：希望将文件传到服务器上的指定路径

# 四、安装Miniforge

服务器终端中，使用chmod命令给Miniforge安装包添加执行权限。假设下载的文件名为Miniforge3-26.3.2-3-Linux-x86_64.sh，则执行

```
chmod +x Miniforge3-26.3.2-3-Linux-x86_64.sh
```

bash指令执行安装

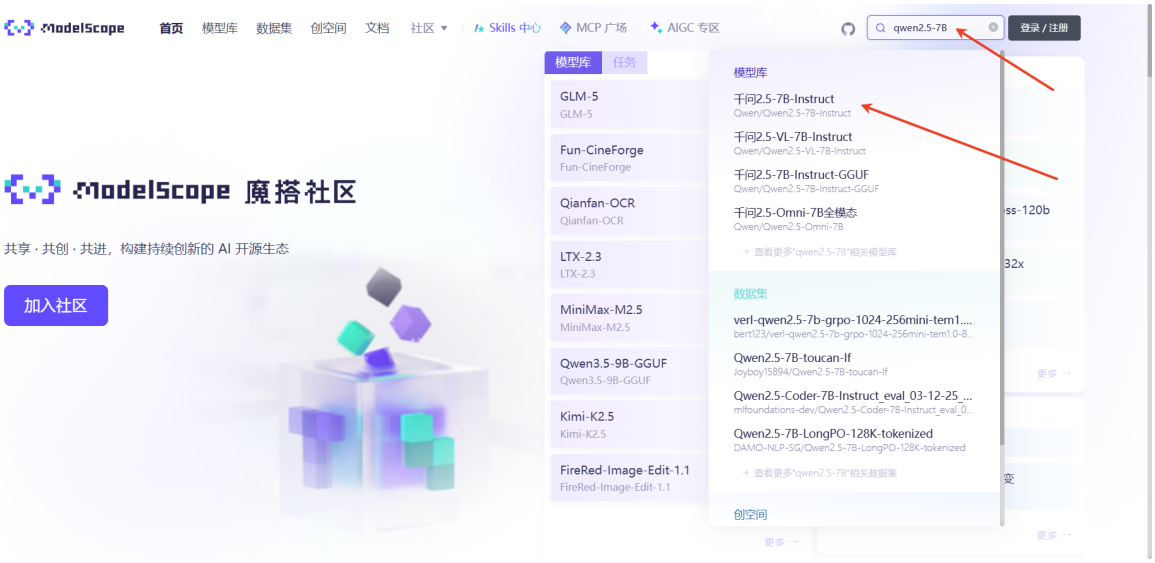
```
bash Miniforge3-26.3.2-3-Linux-x86_64.sh
```

最后激活一下环境变量，就可以正常使用Miniforge了

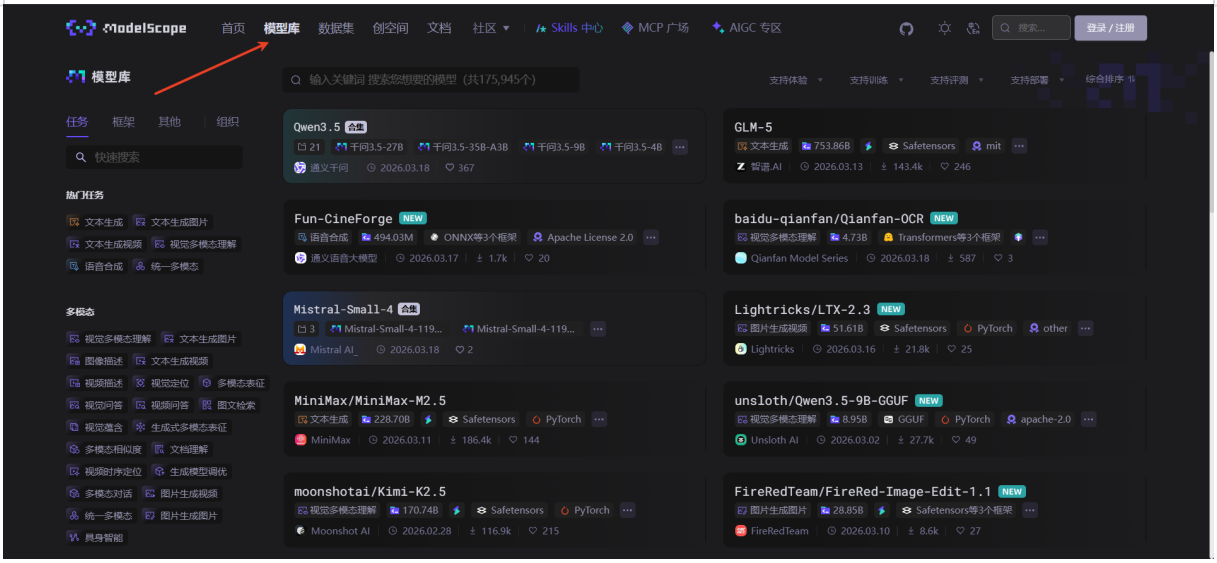
```
source ~/.bashrc
```

# 五、模型准备

可以在ModelScope或者hf-mirror上进行，以ModelScope为例，访问网址链接 https://modelscope.cn/home ，在搜索框输入需要下载的模型




也可以在模型库这里去按类别筛选寻找需要的模型




以qwen2.5-7b-instruct为例，在服务器终端先创建一个conda环境用于管理modelscope的环境依赖，要求python版本为3.11或以上

```
conda create -n modelscope python=3.11 -y
```

如果出现网络报错问题无法正常创建conda环境可以通过指定镜像源进行

```
conda create -n modelscope python=3.11 -c
https://mirrors.tuna.tsinghua.edu.cn/anaconda/pkgs/main -c
https://mirrors.tuna.tsinghua.edu.cn/anaconda/pkgs/free -c
https://mirrors.tuna.tsinghua.edu.cn/anaconda/cloud/conda-forge
--override-channels
```

激活并进入该环境，安装modelscope需要的依赖

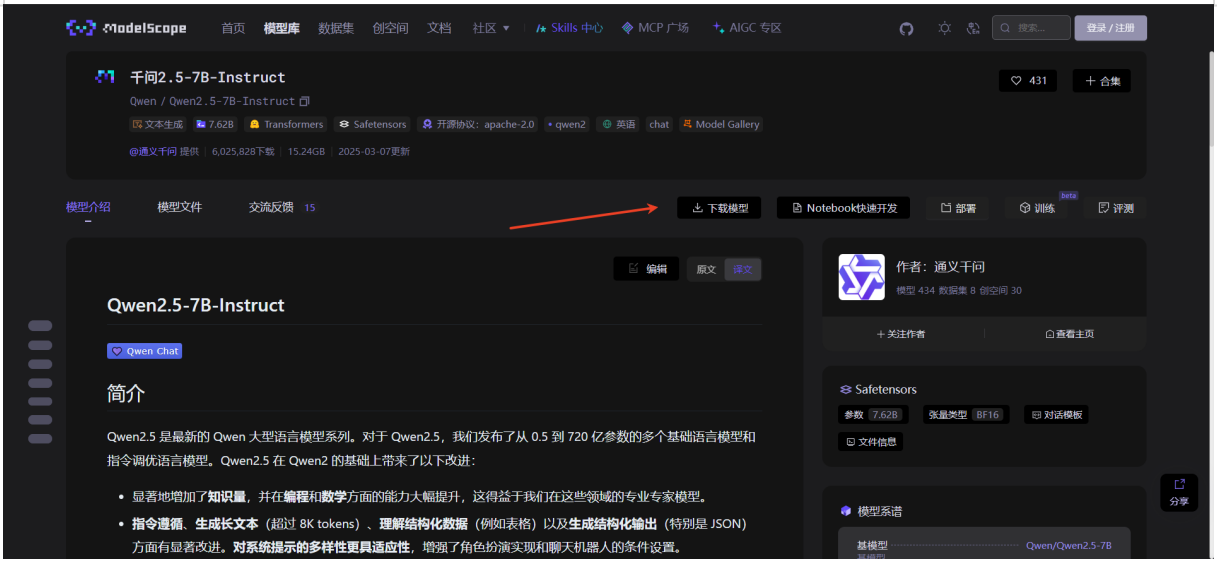
```
conda activate modelscope
pip install modelscope
```

执行命令并进行模型下载

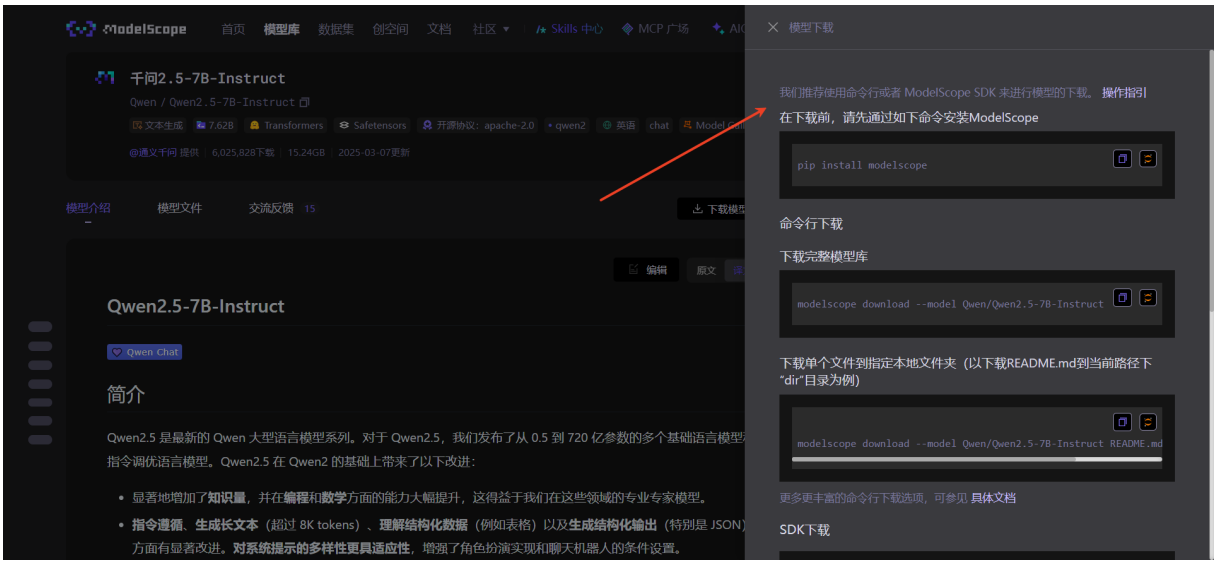
```
modelscope download --model Qwen/Qwen2.5-7B-Instruct --local_dir ./dir
```

- modelscope download：使用modelscope进行模型下载
- --model Qwen/Qwen2.5-7B-Instruct：下载Qwen/Qwen2.5-7B-Instruct的模型文件
- --local_dir ./dir：下载到当前本地路径下的dir子文件夹里

如果需要下载其它的模型，步骤同理，详细步骤可以去到对应模型的网页，点击下载模型

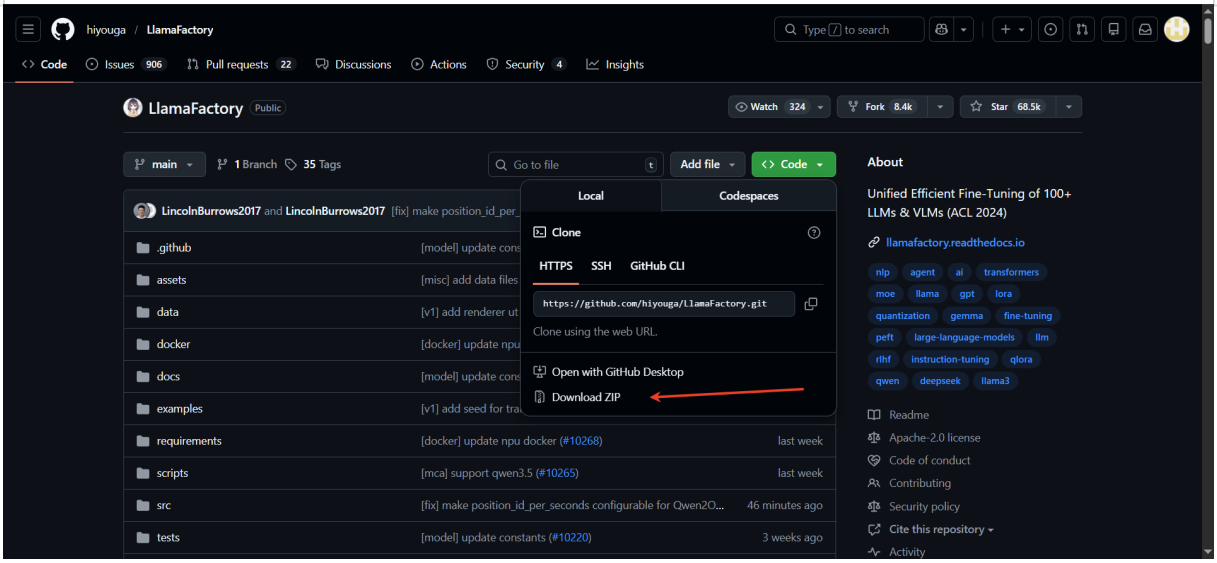



右侧有详细下载流程




# 六、LlamaFactory环境配置

LlamaFactory可以本地进行压缩包下载，解压后通过scp命令上传至服务器，下载网址：
🔗 GitHub - hiyouga/LlamaFactory: Unified Efficient Fine-Tuning of 100+ LLMs & VLMs (A...




下载完成记得一定**解压完成**再通过scp指令上传到服务器，scp指令详细见第三点
创建一个conda环境用于管理llamafactory的环境依赖，要求python版本为3.11或以上

```
conda create -n llamafactory python=3.11 -y
```

如果出现网络报错问题无法正常创建conda环境可以通过指定镜像源进行

```
conda create -n llamafactory python=3.11 -c
https://mirrors.tuna.tsinghua.edu.cn/anaconda/pkgs/main -c
https://mirrors.tuna.tsinghua.edu.cn/anaconda/pkgs/free -c
https://mirrors.tuna.tsinghua.edu.cn/anaconda/cloud/conda-forge
--override-channels
```

进入llamafactory根目录下

```
cd LLaMA-Factory
```

安装llamafactory相关依赖（可使用**清华镜**像源加快下载依赖速度）

```
conda activate llamafactory
pip install -e ".[torch,metrics]"
```

# 七、Lora微调

明确三件事
- LlamaFactory是微调使用的推理框架，Lora是具体训练方法
- 微调所需的相关配置都存放在llamafactory的yaml文件中
- 数据集配置文件需要修改

llamafactory/data/dataset_info.json里添加一项自己的数据集配置，比如

```
"processed_all":# 数据集名称，可以自己任意起，但不能和其它已有数据集名称重复
{
    "file_name":"llamafactory/data/processed_all.json"# 数据集文件的完整路径
},
```

进入到llamafactory目录下以及装好llamafactory依赖的conda环境下（最新版的yaml配置文件已经从llam3_lora_sft变成qwen3_lora_sft了）
微调使用的三条指令提前明确

```
# 训练（依据配置文件模板examples/train_lora/llama3_lora_sft.yaml）
llamafactory-cli train examples/train_lora/llama3_lora_sft.yaml

# 推理（依据配置文件模板examples/inference/llama3_lora_sft.yaml）
llamafactory-cli chat examples/inference/llama3_lora_sft.yaml

# 合并（依据配置文件模板examples/merge_lora/llama3_lora_sft.yaml）
llamafactory-cli export examples/merge_lora/llama3_lora_sft.yaml
```

在执行前，确保对应配置文件已完成必要参数的修改并保存
训练配置文件（以examples/train_lora/llama3_lora_sft.yaml为例）

```
# 模型相关配置
model_name_or_path: your_model_path  # 预训练模型路径（修改为你服务器上模型存放路径）

# 数据集配置
dataset: processed_all  # 修改为之前llamafactory/data/dataset_info.json里添加的数据集名称
template: qwen          # 修改为你要训练的模型模板

### 输出配置
output_dir: your_output_path  # 微调结果保存路径
```

推理配置文件（以examples/inference/llama3_lora_sft.yaml文件为例）

```
# 模型配置
model_name_or_path: your_model_path  # 原始基础模型路径（修改为你服务器上微调前原模型存放路径）
adapter_name_or_path: your_output_path  # 微调结果存放路径（修改为你第一步微调输出结果的保存路径）

template: qwen          # 模型模板（保持训练/推理一致性）
```

模型合并（以examples/merge_lora/llama3_lora_sft.yaml文件为例）

```
# 模型配置
model_name_or_path: your_model_path  # 原始基础模型路径（修改为你服务器上微调前原模型存放路径）
adapter_name_or_path: your_output_path  # 微调结果存放路径（修改为你第一步微调输出结果的保存路径）
template: qwen          # 模型模板（保持训练/推理/合并一致性）

### 导出配置
export_dir: your_export_path # 合并完成的最终模型存放路径
```

这些是最基础的需要修改的配置，其余微调参数配置详细可参照《A4微调笔记》文档
修改并保存完成配置文件后，即可依次使用三条llamafactory微调指令进行训练、推理、合并

ps： 微调效果评估通常是两个方面
●第一步训练配置文件中如果有设置plot_loss: true # 绘制损失曲线图，训练后微调输出目录可以看到微调损失曲线图，持续平缓下降，过程中没有大起大落，最终趋于稳定的较低值没有明显回升，表示效果比较好
●推理过程中去进行大量提问进行人工评估，大多数情况下人工评估会根据最初的微调任务目标，建立一套评分标准去看它的回复是否达到要求，比如普遍达到85分就可以视作微调效果ok，有的公司可能还会让这一领域的专家去测评，也即人工评估是最重要的评估依据
●微调输出的效果如果不太满意通常是需要去再对数据集的质量进行一个把控，或者微调参数的调整
●要明确所有技术都不是为了单一解决某个问题存在的，不可能说单纯通过微调就能够完成一个多么完美的效果出来，实际开发过程中更多的是rag+微调搭配着共同起作用的

# 八、vllm部署模型

微调完全结束后，即可对合并好的最终模型进行私有化部署
vllm是一个推理部署框架，让模型可以通过接口进行访问调用
创建一个conda环境用于管理vllm的环境依赖，要求python版本为3.10或以上

```
conda create -n vllm python=3.10 -y
```

如果出现网络报错问题无法正常创建conda环境可以通过指定镜像源进行

```
conda create -n vllm python=3.10 -c
https://mirrors.tuna.tsinghua.edu.cn/anaconda/pkgs/main -c
https://mirrors.tuna.tsinghua.edu.cn/anaconda/pkgs/free -c
https://mirrors.tuna.tsinghua.edu.cn/anaconda/cloud/conda-forge
--override-channels
```

激活并进行vllm依赖的下载安装

```
conda activate vllm
pip install vllm
```

在该conda环境下对模型进行vllm部署

```
python3 -m vllm.entrypoints.openai.api_server \
--model <合并后模型位置> \
--served-model-name <部署后model调用的名字> \
--gpu-memory-utilization 0.3 \
--max-model-len 1024 \
--dtype=half \
--port <自定义端口号（20000-30000）
```

启动后需保持终端服务是运行状态
如果遇到libstdc++.so.6动态库的版本过低，缺少CXXABI_1.3.15的报错导致部署失败，可在conda环境中执行

```
conda install libstdcxx-ng -c
https://mirrors.tuna.tsinghua.edu.cn/anaconda/pkgs/main -c
https://mirrors.tuna.tsinghua.edu.cn/anaconda/pkgs/free -c
https://mirrors.tuna.tsinghua.edu.cn/anaconda/cloud/conda-forge
--override-channels
```

完成后即可正常部署
可以进行简单的接口测试

- 输入curl命令查看对应端口的模型服务：

```
curl http://127.0.0.1:22222/v1/models
```

- 输入curl命令直接调用对话api：

```
curl http://localhost:22222/v1/chat/completions \
-H "Content-Type: application/json" \
-d '{
    "model": "Qwen2.5-7B-Instruct-lora",
    "messages": [
        {"role": "system", "content": "You are a helpful assistant."},
        {"role": "user", "content": "你好"}
    ],
    "max_tokens": 512
}'
```

https://aiqnmsg.cn/login

# 九、Flask服务端部署

服务端代码

```
import json
from flask import Flask, request, Response, jsonify
from langchain_openai import ChatOpenAI
import logging

logging.basicConfig(level=logging.INFO)
logger = logging.getLogger(__name__)
chat_model = ChatOpenAI(
  model="Qwen2.5-7b-sft", # 部署的模型路径 vllm部署后model调用的名字
  api_key="EMPTY", # 调用不需要 API key
  openai_api_base="http://localhost:22222/v1" #  API 基础地址22222为你vllm部署的时候自定义的端口号
)
app = Flask(__name__)
@app.route('/chat', methods=['POST'])
def chat_api():
# 从请求中获取数据
  data = request.json
  request_id = data.get('request_id')
  phone_number = data.get('phone_number')
  query = data.get('query')
  logger.info("正在处理请求: %s", request_id)
  logger.info("正在处理用户: %s", phone_number)
  logger.info("正在处理问题: %s", query)
  if not request_id or not phone_number or not query:
    return jsonify({"error": "Missing required fields"}), 400
  # 创建一个生成器来逐块返回数据
  def generate_response():
    for chunk in chat_model.stream(query):
      if not chunk.content:
        continue
      json_chunk = json.dumps({
        "request_id": request_id,
```

sss

参考代码示例仅需修改两处部分即可直接使用

- 模型端口号需和vllm部署端口号保持一致

```
chat_model = ChatOpenAI(
    model="Qwen2.5-7B-law",  # 本地模型路径 vllm部署后model调用的名字
    api_key="EMPTY",  # 本地调用不需要 API key
    openai_api_base="http://localhost:22222/v1"  # 本地 API 基础地址22222为你vllm不熟的时候自定义的端口号
)
```

- flask端口需向助教老师进行单独申请

```
            yield json_chunk + '\n'  # 每个 JSON 块后面加上换行符
        # 使用 Flask 的 Response 对象来返回流式响应
        return Response(generate_response(), content_type='application/json')
    if __name__ == '__main__':
        app.run(host='0.0.0.0', port=20994, threaded=True)
```

创建Flask代码运行需要的conda环境

创建一个conda环境用于管理Flask代码的环境依赖，要求python版本为3.10或以上

```
conda create -n flask python=3.10 -y
```

如果出现网络报错问题无法正常创建conda环境可以通过指定镜像源进行

```
conda create -n flask python=3.10 -c
https://mirrors.tuna.tsinghua.edu.cn/anaconda/pkgs/main -c
https://mirrors.tuna.tsinghua.edu.cn/anaconda/pkgs/free -c
https://mirrors.tuna.tsinghua.edu.cn/anaconda/cloud/conda-forge
--override-channels
```

激活并进行服务端代码运行所需依赖的安装

```
conda activate flask
pip install flask
pip install langchain_community
pip install openai
```

在该conda环境下运行服务端代码

```
python server.py
```

启动后需保持终端服务是运行状态

可进行简单测试，用curl命令测试通过flask端口调用chat接口：

```
curl -X POST http://127.0.0.1:20994/chat \
-H "Content-Type: application/json" \
-d '{
"request_id": "12345",
"phone_number": "13800138000",
"query": "劳动法对加班做了哪些规定"
}'
```

# 十、微调展示平台部署

vllm和flask服务均启动后，可在微调展示平台进行配置
- OJAC微调展示平台网址： https://aiqnmsg.cn/login
- 登录方式：手机号+验证码

点击加号，创建智能体




在微调后API处输入url，url和助教老师单独申请（只填微调后），设为**非公开**




完成后点击即可进行对话

测试完成之后要把微调后的模型、服务端代码、各环节指令等保存到本




地，以便于后续面试环节展示使用，保存方式同样在本地终端（注意不是linux）使用scp指令

# 十一、实战报告提交

完成A4实战实操之后需要整理成项目报告进行提交。
项目报告需要包含：微调原因，数据集来源，数据集整理（清洗）流程，微调方法，微调前后对比。

实战报告提交链接：
https://candidate.aidexianzhaopinguan.com/newexam/ede4f60e0f82478bb59c4c1e96d...